

Clasificación de tipos de cielo basado en mediciones de
radiación solar

Giovanni Gamaliel López Padilla

Índice

1. Introducción	2
2. Modelos de irradiancia solar	2
2.1. Irradiancia solar extraterrestre	2
2.2. Declinación y ángulo solar	2
2.3. Irradiancia solar global horizontal	2
3. Sistema de Monitoreo Ambiental	3
4. Creación de la base de datos	4
4.1. Criterios para las condiciones de cielo despejado	4
4.2. Distribución de los datos	5
4.3. Datos atípicos	5
4.4. Reconstrucción	6
5. Modelos de clasificación	7
5.1. Modelos clásicos	7
5.2. Modelos basados en redes neuronales	8
5.3. Métricas	12
6. Resultados	12
7. Discusión y conclusiones	12
8. Referencias	12

1. Introducción

2. Modelos de irradiancia solar

Los modelos de irradiancia solar pueden estimar el valor de irradiancia solar bajo condiciones de cielo despejado.¹⁻³ Las estimaciones obtenidas por los modelos son usados para realizar comparaciones sobre mediciones de una locación, las cuales pueden contener datos inexistentes o ruido. Existen diversos modelos basados en redes neuronales donde a partir de parámetros geoespaciales ó datos meteorológicos estiman el promedio por hora, día, mes o año.⁴⁻⁷ Estos modelos requieren que la información de entrada sea detallada, por lo que representa un problema, aunado a esto, los modelos estan delimitados por la precisión que tienen sus estimaciones.⁸ En este trabajo se propone el uso de modelos simples que pueden adaptarse a la localidad pero con la suficiente precisión para estimar la irradiancia global bajo condiciones de cielo despejado.

2.1. Irradiancia solar extraterrestre

El modelo de irradiancia solar extraterrestre (GHI_0) esta definido de la siguiente manera.⁹

$$GHI_0 = I_{SC} \left[1 - 0.033 \cos \left(\frac{360n}{365} \right) \right] \cos(z) \quad (1)$$

Donde I_{SC} la constante solar con valor de 1367 W/m^2 , n es el día consecutivo del año ($n=1$ es el primer día año y 365 es el último día del año, para años bisiestos el denominador cambia a 366 y el último día se toma como 366) y z es el ángulo zenital definido de la siguiente manera:

$$\cos(z) = \cos(\phi)\cos(\delta)\cos(\omega) + \sin(\phi)\sin(\delta) \quad (2)$$

Donde ϕ, δ, ω son la latitud, declinación solar y el ángulo solar de la locación y la hora local.

2.2. Declinación y ángulo solar

La dependencia en el tiempo en la ecuación 1 se introduce por medio de la declinación solar (ecuación 3) y el ángulo solar (ecuación 4), donde h_{LTC} es la hora local y γ es la fracción de rotación de la tierra con respecto al sol.

$$\delta = 24.45 \sin(\gamma) \quad (3)$$

$$\omega = 15(h_{LTC} - 12) \quad (4)$$

2.3. Irradiancia solar global horizontal

Kwarikunda¹⁰ menciona que realizaron comparaciones entre los modelos Berger-Duffie (BD), Adnot-Bouges-Campana-Gicquel (ABCG) y Robledo-Soler (RS) para obtener el modelo que realiza una estimación más cercana a las mediciones realizadas en diferentes locaciones con el piranómetro CMP10, el cual realiza mediciones en el rango 285-2800 nm. El modelo RS es el que obtiene una mejor estimación de la irradiancia solar a nivel del suelo. El modelo RS se encuentra definido en la ecuación 5.

$$GHI_{RS} = a(\cos z)^b \exp(-c(90 - z)) \quad (5)$$

donde $\cos z$ es el angulo zenital y a, b, c son constantes a determinar. En la tabla 1 se encuentran los parámetros usados para el modelo.

Parametro	a	b	c
Valor	1119	1.19	1×10^{-6}

Tabla 1: Parámetros del modelo RS.

3. Sistema de Monitoreo Ambiental

El Área Metropolitana de Monterrey (AMM) se ubica en una región montañosa donde se realizan extracciones de material para la construcción (pedreras) a la par de actividades industriales y alto flujo vehicular. El Sistema de Monitoreo Ambiental (SIMA) tiene como objetivo evaluar la calidad del aire, monitoreando las concentraciones de contaminantes atmosféricos a las que se encuentra expuesta la población del AMM y, bajo condiciones adversas, advertir sobre los periodos de altos índices de contaminación atmosférica. El SIMA se compone de 13 estaciones de monitoreo repartidas a lo largo del AMM (figura 1).




Figura 1: Ubicación geográfica de las estaciones meteorológicas del SIMA en el AMM.

En la tabla 2 se muestra la información geográfica de las estaciones meteorológicas del SIMA en el AMM.

Ciudad	Nombre	Elevación (m s. n. m.)	Latitud (°N)	Longitud (°O)
Guadalupe	Sureste	492	25.6680	-100.2490
Monterrey	Centro	560	25.6700	-100.3380
Monterrey	Noroeste	571	25.7570	-100.3660
San Nicolas de los Garza	Noreste	476	25.7500	-100.2550
Santa Catarina	Suroeste	694	25.6760	-100.4640
Garcia	Noroeste2	716	25.7830	-100.5860
Escobedo	Norte	528	25.8000	-100.3440
Apodaca	Noreste2	432	25.7770	-100.1880
Juarez	Sureste2	387	25.6460	-100.0960
San Pedro Garza Garcia	Suroeste2	636	25.6650	-100.4130
Cadereyta de Jimenez	Sureste3	340	25.5833	-99.9872
Monterrey	Sur	630	25.5749	-100.2489
San Nicolas de los Garza	Norte2	520	25.7295	-100.3099

Tabla 2: Información de la localización geográfica de las estaciones meteorológicas del SIMA en el AMM.

Se conto con una base de datos que contiene mediciones de irradiancia solar por hora en las estaciones del SIMA en el periodo 1993-2021. Se realizo un conteo de los meses que cumplen las siguientes condiciones:

- Un día valido es aquel que contiene al menos 10 mediciones en el periodo de las 8 a las 19 horas.
- Un mes valido es aquel que contiene al menos 21 días validos.

En la figura 2 se muestra la distribución de los meses validos en las estaciones del SIMA bajo las condiciones anteriores.




Figura 2: Distribución de los meses validos para las estaciones meteorológicas del SIMA en el periodo 1993-2021.

4. Creación de la base de datos

Se seleccionaron las estaciones noroeste, noreste, sureste2 y suroeste en el periodo 2019-2021. Estas estaciones fueron elegidas debido a que la geografía alrededor es muy diferente y porque presentan un gran número de mediciones dentro del periodo seleccionado. En base a las mediciones diarias de cada estación se clasificó visualmente la condición de cielo para cada día. Las condiciones de cielo contempladas son despejado, parcialmente nublado y nublado.

4.1. Criterios para las condiciones de cielo despejado

Los criterios para la clasificación de cielo despejado de manera visual de las mediciones diarias son las siguientes:

- Cielo despejado
 - Un día de cielo despejado se caracteriza por tener un comportamiento gaussiano a lo largo del día, teniendo como máximo el mediodía solar. Para el AMM, el mediodía solar debe encontrarse alrededor de las 12:30-14:30 horas. Las mediciones deben registrar un valor diferente a cero entre las 6 a las 20 horas.
- Cielo parcialmente nublado
 - Un día de cielo parcialmente nublado se caracteriza por presentar el comportamiento de un día con cielo despejado pero en ciertos intervalos de tiempo. Esto puede ocurrir en solo una hora, o en varias. Si el día contiene entre uno y cinco mediciones que caracterizan a un día despejado, entonces el día será clasificado como parcialmente nublado.
- Cielo nublado
 - Un día nublado se caracteriza por presentar un comportamiento caótico o un comportamiento gaussiano pero con valores más bajos en comparación a un día de cielo despejado.

En la figura 3 se presentan diferentes mediciones para visualizar las diferentes clasificaciones de las condiciones de cielo.

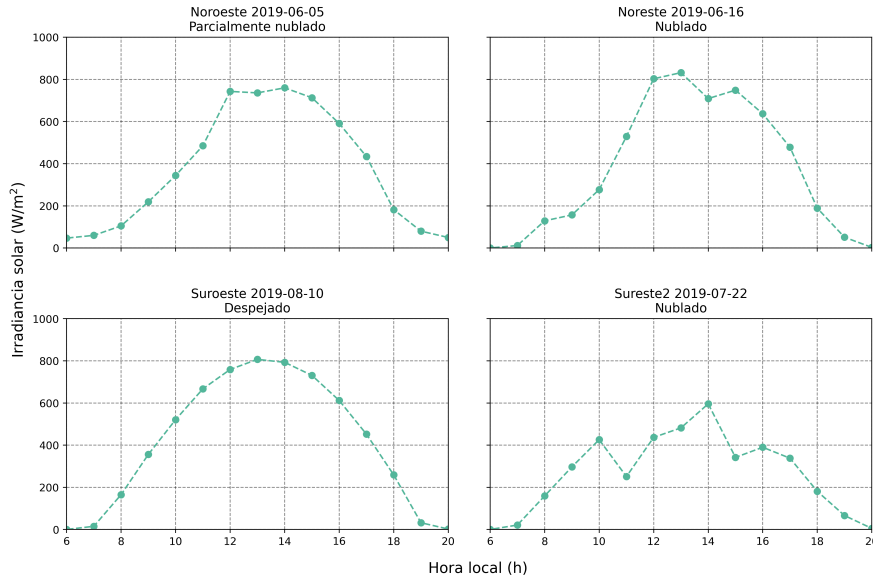


Figura 3: Ejemplos de las clasificaciones de las condiciones de cielo a partir de mediciones diarias de cada una de las estaciones del SIMA.

4.2. Distribución de los datos

En la figura 4 se muestra la distribución de las condiciones de cielo clasificadas de manera visual, en esta se observa que existe una mayor cantidad de días nublados en comparación de los días categorizados como despejado o parcialmente nublado.




Figura 4: Distribución de las clasificaciones de las condiciones de cielo en la base de datos.

4.3. Datos atípicos

Los datos de las estaciones del SIMA pueden contener ruido o mediciones que físicamente no son posibles, a estos datos los denominamos como atípicos. Se implementó una limpieza de datos automática la cual consiste en realizar una operación de comparación para cada medición (ecuación 6) con respecto al modelo GHI, si esta operación para alguna hora es mayor a 0.9, entonces este valor corresponde a una medición atípica y se eliminará de la base de datos. Si el k_t es igual a 0, entonces se sobrescribe la medición con el valor 0, esto con el propósito de eliminar el ruido que puede tener el radiómetro de la estación analizada.

$$k_t = \begin{cases} \frac{\text{Medición}}{\text{GHI}_0} & \text{si } \text{GHI}_0 \neq 0 \\ 0 & \text{si } \text{GHI}_0 = 0 \end{cases} \quad (6)$$

En la figura 5 se visualiza en dos días diferentes el proceso de la limpieza de datos atípicos. Los valores atípicos ocurren con frecuencia al inicio o al final del día solar.




Figura 5: Mediciones de irradiancia solar de la estación noroeste originales (izquierda) y sin valores atípicos (derecha).

4.4. Reconstrucción

A partir de los datos limpios, se aplicó un proceso de reconstrucción. El proceso de reconstrucción consiste en asignar el valor del promedio horario de las 10 primeras mediciones que tengan más semejanza a la medición a reconstruir. Se toman únicamente las mediciones de la misma estación en una ventana de tres meses (un mes anterior, el mes actual y el siguiente). La semejanza se calcula en base a la similitud coseno (ecuación 7).

$$sim(m_i, m_j) = \frac{m_i \cdot m_j}{||m_i|| ||m_j||} \quad (7)$$

En la figura 6 se muestran los datos restaurados para los casos presentados en la figura 5.




Figura 6: Restauración de mediciones por medio de promedios horarios de las 30 mediciones más semejantes al día seleccionando

Con las mediciones restauradas se realizaron las comparaciones (ecuación 8 y ecuación 9) con respecto a los modelos GHI_0 y RS.

$$d_t = \begin{cases} \text{Modelo} - \text{Medición} & \text{si Modelo} \neq 0 \\ 0 & \text{si Modelo} = 0 \end{cases} \quad (8)$$

$$k_t = \begin{cases} \frac{\text{Medición}}{\text{Modelo}} & \text{si Modelo} \neq 0 \\ 0 & \text{si Modelo} = 0 \end{cases} \quad (9)$$

5. Modelos de clasificación

Los modelos de clasificación han sido aplicados en el área de la física de la atmósfera, tal como la clasificación de la sustentabilidad de una ciudad,¹¹ clasificación de contaminantes en el agua por medio de videos¹² y clasificación del efecto toxico en base a la concentración de contaminantes en peses.¹³

5.1. Modelos clásicos

Tradicionalmente la solución a los problemas de clasificación se ha realizado por medio de modelos estadísticos ó geométricos. El rendimiento del modelo dependerá del patrón de correlaciones que mantengan los predictores con la información de entada. En este trabajo se implementaron los modelos Support Vector Machine (SVM), K vecnos más cercanos (KNN), Árbol de decisión, Bosque Aleatorio y Naives Bayes Gaussiano.

Support Vector Machine El algoritmo de Support Vector Machine (SVM) es un algoritmo de aprendizaje supervisado que se utiliza en problemas de clasificación y regresión. El objetivo del algoritmo SVM es encontrar un conjunto de hiperplanos que separen de la mejor manera posible a las clases de los datos dados. Cada hiperplano resultante tendra un margen amplio entre cada clase de datos. El margen se define como la distancia máxima a la región paralela al hiperplano que no contiene datos en su interior. Existen funciones las cuales pueden transformar las características del hiperplano, estas funciones son llamadas funciones kernel. En la tabla 3 se encuentran las diferentes funciones kernel que son mayormente usadas.

Función	Kernel
Gaussiana	$K(x_1, x_2) = \exp\left(-\frac{\ x_1 - x_2\ ^2}{2\sigma^2}\right)$
Lineal	$K(x_1, x_2) = x_1^T x_2$
Polinomial	$K(x_1, x_2) = (x_1^T x_2 + 1)^\rho$
Sigmoide	$K(x_1, x_2) = \tanh(\beta_0 x_1^T x_2 + \beta_1)$

Tabla 3: Funciones kernel con los parámetros de cada función.

KNN El algoritmo de k vecinos más cercanos, también conocido como KNN o k-NN, es un algoritmo de aprendizaje supervisado no paramétrico. El algoritmo usa la proximidad para realizar una clasificación o una predicción. Generalmente el algoritmo se usa como un modelo de clasificación. Para problemas de clasificación se asigna una etiqueta de clase en base al número que se presenta con mayor frecuencia alrededor del punto dado. Para este caso se utilizo la metrica de minkowski con $p = 2$ y considerando los 3 vecinos más cercanos.

Árbol de decisión Un árbol de decisión es un modelo basado en el aprendizaje supervisado. El modelo divide el espacio de predictores aplicando una serie de reglas o decisiones en la que contenga la mayor proporción posible de individuos de una de las categorías dadas. En este trabajo se utilizo la función gini para entrenar el modelo.

Bosques aleatorios El algoritmo de bosque aleatorio es un algoritmo de aprendizaje supervisado, el cual esta basado en un conjunto de árboles de decisión combinados con un método de votación. En este trabajo se utilizo la función gini para entrenar el modelo y 1000 estimadores.

Naive Bayes Gaussiano El algoritmo Naive Bayes Gaussiano es un algoritmo de aprendizaje supervisado. El algoritmo esta basado en el teorema de bayes. La asunción que toma el algoritmo es la independencia entre las categorías. E

5.2. Modelos basados en redes neuronales

A partir de 1986,¹⁴ los modelos conexionistas o redes neuronales han sido utilizados como herramientas de predicción y clasificación. Un modelo basado en redes neuronales es un sistema informático que mediante el uso de pesado auto-modificable.

Perceptrón El perceptrón fue propuesto por Frank Rosenblatt.¹⁵ El modelo más básico de una neurona es un perceptrón. El perceptrón usa una matriz para representar las redes neuronales, esta matriz es llamada matriz de pesos o solamente pesos. Las componentes de un modelo perceptrón son la capa de entrada, la capa oculta, una función de activación y la salida. En la capa oculta es donde se calcula la mutiplicación con la matriz de pesos. En la tabla 4 se encuentran las funciones más usadas como funciones de activación.

Función	Definición
Lineal	$f(x) = x$
Sigmoide	$f(x) = \frac{1}{1+e^{-x}}$
ReLU	$f(x) = \begin{cases} 0 & \text{si } x < 0 \\ x & \text{si } x \leq 0 \end{cases}$
Tanh	$f(x) = \tanh(x)$

Tabla 4: Funciones de activación comúnmente usadas.

El perceptrón multicapa tiene una estructura similar a la de un modelo perceptrón. En este caso se incluyen capas ocultas donde todas se encuentran conectadas, a esto se le denomina como una capa densa. En cada iteración existe una actualización con propagación hacia atras en las capas densas para entrenar el modelo. En nuestro caso se implemento un perceptrón multicapa con tres capas de 256, 128 y 3 capas densas con la función de activación sigmoide. En la figura 7 se representa de manera visual el modelo perceptrón.




Figura 7: Representación del modelo perceptrón multicapa.¹⁶

En la tabla 5 se muestra el número de parámetros y la salida y entrada de cada capa en el modelo creado.

Capa	Salida	Número de parámetros
Flatten	24	0
Densa 1	256	6400
Densa 2	128	32896
Densa 3	3	387

Tabla 5: Estructura del modelo perceptrón implementado.

Red Recurrente Las redes neuronales recurrentes (RNN) son una clase de redes neuronales que permiten conocer la salida anterior y utilizarla conociendo sus pesos. Para cada tiempo t , la función de activación (a_t) y la salida (y_t) pueden ser calculadas con las ecuaciones 10 y 11.

$$a_t = g_1(W_{aa}a_{t-1} + W_{ax}x_t + b_a) \quad (10)$$

$$y_t = g_2(W_{ya}a_t + b_y) \quad (11)$$

En la figura 8 se visualiza a arquitectura de una RNN.




Figura 8: Ilustración de una red neuronal recurrente.¹⁷

En la tabla 6 se muestra la estructura de la RNN creada para este proyecto. La capa RNN tiene como función de activación a la función ReLU y la capa densa una función sigmoide.

Capa	Salida	Número de parámetros
RNN	64	4224
Densa	3	195

Tabla 6: Estructura del modelo RNN implementado.

Red Convolucional A diferencia de un modelo perceptrón, los modelos de redes neuronales convolucionales (CNN) consta de dos partes, una que se encarga del proceso de la convolución y otra del proceso de la predicción o la clasificación. En el proceso de convolución el objetivo es extraer la información mas relevante para la tarea. La operación convolución es comunmente usada para realizar transformaciones y obtener información de ella.¹⁸⁻²⁰ En nuestro caso, estamos tratando con un vector, por ende la convolución que se aplica sera una restringida en una dimensión. Después del proceso de las capas de convolución se obtienen una serie de vectores de una mayor dimensión, para reducir las mismas pasan por una capa llamada fully connected. La capa más común para realizar este proceso es llamada Max-polling, la cual dentro de una ventana en la serie de vectores obtiene unicamente el máximo. En la figura se muestra un ejemplo de esta capa en una matriz de 4x4.




Figura 9: Ejemplo de la capa Max-polling sobre una matriz de 4x4.²¹

En nuestro caso, en vez de usar una capa de Max-polling se implemento un capa de Global-Average-Polling,²² la cual realiza un promedio de los vectores obtenidos a partir de todas las convoluciones obtenidas. En la figura 10 se muestra un ejemplo de una arquitectura de una CNN.




Figura 10: Arquitectura de una CNN.²³

En la tabla 7 se muestra la estructura del modelo CNN implementado. Las capas convoluciones tienen como función de activación a la función ReLU y la capa densa la función sigmoide.

Capa	Salida	Número de parámetros
Conv1D 1	22,100	400
Conv1D 2	20,200	60200
Conv1D 3	18,200	120200
Global Average	200	0
Densa	3	603

Tabla 7: Estructura del modelo CNN implementado.

Long short-term memory El modelo long short-term memory (LSTM) es una red neuronal la cual contiene propagación hacia atrás semejante a las RNN. La red LSTM es creada para modificar una característica de la red RNN. La característica que se modificada es que en el momento t , el estado oculto de los tiempos anteriores tienen una atribución menor conforme avanza el tiempo. Una red LSTM preserva la contribución de datos importantes independientemente de cuando aparezca. Por lo tanto, puede tener una memoria de corto y largo plazo. En la figura se muestra una celda de la red LSTM. A diferencia de una celda de una red RNN, la LSTM contiene un elemento adicional llamado celda de estado (c_t). La celda de estado es la encargada de preservar la información relevante en cualquier tiempo.




Figura 11: Celda de la red LSTM con sus elementos.²⁴

En la tabla 8 se encuentra la estructura de la red LSTM implementada. La capa densa tiene como

función de activación la función sigmoide.

Capa	Salida	Número de parámetros
LSTM 1	24,256	264192
LSTM 2	256	525312
Densa	3	771

Tabla 8: Estructura del modelo LSTM implementado.

Bidireccional Long-short-term memory El modelo Bidireccional Long short-term memory (Bi-LSTM) añade la característica de analizar los datos de entrada hacia delante y hacia atras. En la figura 12 se muestra la estructura interna de una red Bi-LSTM.




Figura 12: Estructura interna de la red Bi-LSTM.²⁵

En la tabla 9 se muestra la estructura interna del modelo Bi-LSTM implementado.

Capa	Salida	Número de parámetros
Bi-LSTM 1	24,512	528384
Bi-LSTM 2	512	1574912
Densa	3	1539

Tabla 9: Estructura del modelo Bi-LSTM implementado.

Red convolucional con atención La atención es una técnica que toma la idea de la atención cognitiva de los humanos. La idea principal es que el modelo se enfoque en cierta parte de la entrada e ignore la otra, esto por medio de un sistema de pesado. El uso de multiples mecanismos de atención afronta la desventaja que tiene la convolución.^{26,27} Es por ello, que se implemento esta capa de atención en la estructura de la red CNN descrita en la tabla 7. En la tabla 10 se encuentra la estructura de la red CNN con atención implementada.

Capa	Salida	Número de parámetros
Conv1D 1	20,100	600
Conv1D 2	18,200	60200
Conv1D 3	16,200	120200
Global Average	32	52800
Densa	3	99

Tabla 10: Estructura del modelo CNN con atención implementado.

Esquema de votación En base a los modelos neuronales implementados, se desarrollo un esquema de votación en el cual se seleccionan a los tres mejores modelos en base a su precisión para cada estación y se realiza una media aritmética de su resultado final.

5.3. Metricas

Para medir el rendimiento de cada modelo se utilizará como base la matriz de confusión. En la tabla 11 se presenta un ejemplo de una matriz de confusión. Cada columna representa el número de predicciones de cada clase, mientras que las filas representa a las clases reales.

		Clase predicha		
		Nublado	Parcialmente nublado	Despejado
Clase real	Nublado	100	11	1
	Parcialmente nublado	13	42	10
	Despejado	0	4	51

Tabla 11: Ejemplo de una matriz de confusión con las clases de las condiciones de cielo.

Las metricas precision (ecuación 12) y recall (ecuación 13) que se pueden obtener a partir de la matriz de confusión. Estas metricas dependen de cada clase.

$$\text{Precision} = \frac{tp}{tp + fp} \quad (12) \quad \text{Recall} = \frac{tp}{tp + fn} \quad (13)$$

donde tp son el número de predicciones correctamente etiquetadas, fn es el número de predicciones que predicen la inexistencia de cierta característica pero en realidad sí la presentan y fp es el número de predicciones que producen la presencia de cierta característica pero en realidad no la presentan. La metrica F-Score combina los valores de las metricas precision y recall. La metrica F-Score esta definida en la ecuación 14.

$$F = 2 \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} \quad (14)$$

Para resumir la información de las metricas antes mencionadas se utiliza la metrica accuracy. La metrica accuracy esta definida en la ecuación 15.

$$\text{Accuracy} = \frac{\text{Número correcto de predicciones}}{\text{Número total de predicciones}} \quad (15)$$

Para cada modelo se genera un reporte de metricas como el mostrado en la tabla 12.

	Precision	Recall	F-Score
Nublado	0.88	0.89	0.89
Parcialmente nublado	0.74	0.65	0.69
Despejado	0.82	0.93	0.87
Accuracy			0.83

Tabla 12: Ejemplo del reporte de metricas por cada modelo de clasificación.

6. Resultados

7. Discusión y conclusiones

8. Referencias

- [1] Gueymard CA. Clear-sky irradiance predictions for solar resource mapping and large-scale applications: Improved validation methodology and detailed performance analysis of 18 broadband

- radiative models. *Solar Energy*. 2012 aug;86(8):2145-69. Available from: <https://doi.org/10.1016%2Fj.solener.2011.11.011>.
- [2] Pérez-Burgos A, Díez-Mediavilla M, Alonso-Tristán C, Rodríguez-Amigo MC. Analysis of solar direct irradiance models under clear-skies: Evaluation of the improvements for locally adapted models. *Journal of Renewable and Sustainable Energy*. 2017 mar;9(2):023703. Available from: <https://doi.org/10.1063%2F1.4981798>.
- [3] Ineichen P. Validation of models that estimate the clear sky global and beam solar irradiance. *Solar Energy*. 2016 jul;132:332-44. Available from: <https://doi.org/10.1016%2Fj.solener.2016.03.017>.
- [4] Hasni A, Sehli A, Draoui B, Bassou A, Amieur B. Estimating Global Solar Radiation Using Artificial Neural Network and Climate Data in the South-western Region of Algeria. *Energy Procedia*. 2012;18:531-7. Available from: <https://doi.org/10.1016%2Fj.egypro.2012.05.064>.
- [5] Kumar S, Kaur T. Efficient solar radiation estimation using cohesive artificial neural network technique with optimal synaptic weights. *Proceedings of the Institution of Mechanical Engineers, Part A: Journal of Power and Energy*. 2019 oct;234(6):862-73. Available from: <https://doi.org/10.1177%2F0957650919878318>.
- [6] Ozgoren M, Bilgili M, Sahin B. Estimation of global solar radiation using ANN over Turkey. *Expert Systems with Applications*. 2012 apr;39(5):5043-51. Available from: <https://doi.org/10.1016%2Fj.eswa.2011.11.036>.
- [7] Sahan M, Yakut E. Estimation of monthly global solar radiation in the eastern Mediterranean region in Turkey by using artificial neural networks. *EPJ Web of Conferences*. 2016;128:06001. Available from: <https://doi.org/10.1051%2Fepjconf%2F201612806001>.
- [8] Ruiz-Arias JA, Gueymard CA. Worldwide inter-comparison of clear-sky solar radiation models: Consensus-based review of direct and global irradiance components simulated at the earth surface. *Solar Energy*. 2018 jul;168:10-29. Available from: <https://doi.org/10.1016%2Fj.solener.2018.02.008>.
- [9] Iqbal M. *An Introduction To Solar Radiation*; 1983.
- [10] Kwarikunda N, Chiguvare Z. Performance Analysis of Clear Sky Global Horizontal Irradiance Models: Simple Models Adapted for Local Conditions. *Journal of Renewable Energy*. 2021 sep;2021:1-12. Available from: <https://doi.org/10.1155%2F2021%2F4369959>.
- [11] Haldorai A, Ramu A. Canonical Correlation Analysis Based Hyper Basis Feedforward Neural Network Classification for Urban Sustainability. *Neural Process Lett*. 2020 aug;53(4):2385-401. Available from: <https://doi.org/10.1007%2Fs11063-020-10327-3>.
- [12] KangSeung-Ho, JeongIn-Seon, LimHyeong-Seok. A Method for the Classification of Water Pollutants using Machine Learning Model with Swimming Activities Videos of *Caenorhabditis elegans*. *Journal of the Korea Institute of Information and Communication Engineering*. 2021 7;25(7):903-9.
- [13] Verhaar HJM, Solbé J, Speksnijder J, van Leeuwen CJ, Hermens JLM. Classifying environmental pollutants: Part 3. External validation of the classification system. *Chemosphere*. 2000 apr;40(8):875-83. Available from: <https://doi.org/10.1016%2Fs0045-6535%2899%2900317-3>.
- [14] Rumelhart DE, McClelland JL. In: *A General Framework for Parallel Distributed Processing*; 1987. p. 45-76.
- [15] Rosenblatt F. The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*. 1958;65(6):386-408. Available from: <https://doi.org/10.1037%2Fh0042519>.
- [16] Isaksson M. Create a drawing of a feed-forward neural network.; 2021. Available from: <https://github.com/martisak/dotnets>.

- [17] Amidi S, Amidi A. Recurrent Neural Networks cheatsheet;. Available from: <https://stanford.edu/~shervine/teaching/cs-230/cheatsheet-recurrent-neural-networks>.
- [18] Unser M, Thevenaz P, Yaroslavsky L. Convolution-based interpolation for fast, high-quality rotation of images. *IEEE Transactions on Image Processing*. 1995;4(10):1371-81.
- [19] Boellaard R, van Herk M, Mijnheer BJ. A convolution model to convert transmission dose images to exit dose distributions. *Med Phys*. 1997 feb;24(2):189-99. Available from: <https://doi.org/10.1118%2F1.598066>.
- [20] Gao H, Choi HF, Claus P, Boonen S, Jaecques S, van Lenthe GH, et al. A fast convolution-based methodology to simulate 2-Dd/3-D cardiac ultrasound images. *IEEE Trans Ultrason, Ferroelect, Freq Contr Transactions on Ultrasonics, Ferroelectrics and Frequency Control*. 2009 feb;56(2):404-9. Available from: <https://doi.org/10.1109%2Ftuffc.2009.1051>.
- [21] Jauregui Fernández A. Qué son y cómo crear una red neuronal convolucional con Keras;. Available from: <https://anderfernandez.com/blog/que-es-una-red-neuronal-convolucional-y-como-crearlaen-keras/>.
- [22] Lin M, Chen Q, Yan S. Network In Network; 2013. Available from: <https://arxiv.org/abs/1312.4400v3>.
- [23] Qu L, Wu C, Zou L. 3D Dense Separated Convolution Module for Volumetric Medical Image Analysis. *Applied Sciences*. 2020 jan;10(2):485. Available from: <https://doi.org/10.3390%2Fapp10020485>.
- [24] Rahuljha. LSTM Gradients; 2020. Available from: <https://towardsdatascience.com/lstm-gradients-b3996e6a0296>.
- [25] Deep Dive into Bidirectional LSTM; 2019. Available from: <https://www.i2tutorials.com/deep-dive-into-bidirectional-lstm/>.
- [26] Chen Y, Kalantidis Y, Li J, Yan S, Feng J. A^2 -Nets: Double Attention Networks; 2018.
- [27] Chen Y, Fan H, Xu B, Yan Z, Kalantidis Y, Rohrbach M, et al.. Drop an Octave: Reducing Spatial Redundancy in Convolutional Neural Networks with Octave Convolution; 2019.